C++ Jezgro za Jupyter Notebook

Seminarski rad u okviru kursa
Metodologija stručnog i naučnog rada
Matematički fakultet

Goran Vinterhalter, Marko Ranković
gvinterhalter@gmail.com, marko.rankovic@outlook.com

14. april 2016.

Sažetak

C++ Jezgro pretstavlja softver koji pokušava da emulira interpretiranje c++ tehnikama dinamičkog učitavanja pa izvršavanja. Zapravo funkcioniše kao shell za C++ ali može biti korišćen kao jezgro koje izvršava zahteve web aplikacij Jupyter Notebook.

Sadržaj

1 Uvod

Jupyter Notebook je web aplikacija za kreiranje i deljenje dokumenata koji pored uobičajenog tekstualnog sadržaja sadrže i interaktivni kod. [3]

Dokument je sačinjen iz niza ćelija koje vizuelno mogu biti podeljene na ćelije običnog teksta (markdown) i ćelije koda. Tokom izvršavanja, ćelijama koda biće pridružene ćelije sa rezultatima. Dokumenti se čuvaju u JSON formatu a prikazuju se unutar web pregledača. Na slici 1 možemo videti primer notebook fajla u JSON obliku i prikaza u web pregledaču.

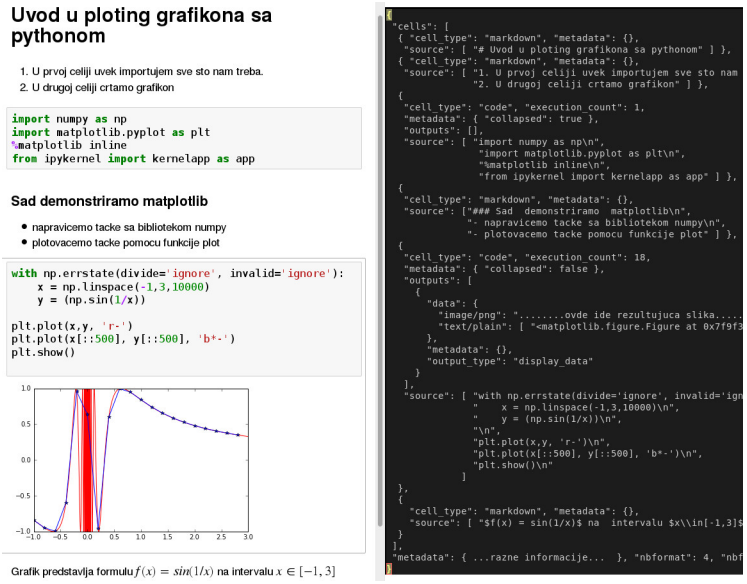

Slika 1: Notebook primer

2 Arhitektura

Arhitektura softvera je server/klijent. [5] Serverski deo je sačinjen iz dve komponente kao što se da videti na slici 2. [5]

1. Notebook server komunicira sa web pregledačem i dozvoljava kreiranje, gledanje i editovanje ćelija običnog teksta.
2. Jezgro (engl. *Kernel*) je proces koji kao ulaz prima ćelije koda a vraća evaluiran izlaz. Pored toga Jezgro je takođe zaduženo za stvari kao što su: samoispitivanje (engl. *introspection*), dovršavanje koda (engl. *code completition*), dokumentacija itd.

Jezgro je prilagođeno za specifičan jezik. Recimo IPython jezgro izvršava python kod dok postoje i: IJulia, IRuby, IHaskell, IJavaScript, IRKernel i mnogi drugi. Cilj ovog seminarskog rada je da izuči mogućnosti pravljenje jezgra za jezik c++ i izradi prototipa. Na prvi pogled problem deluje trivijalan, ćelije se kompajliraju i izvršavaju, ali nije baš tako.

Jupyter notebook se inicijalno zvao IPython notebook i razvio se iz IPython projekta koji pretstavlja front end za python interpreter. Primarni cilj Ipython notebook projekta je bio interaktivna platforma u kojoj

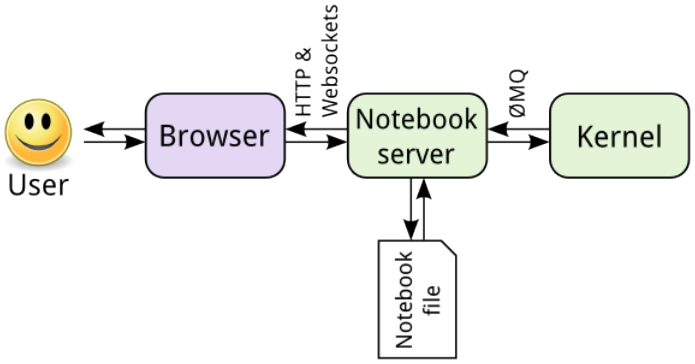

Slika 2: Klijent Server arhitektura

bi korisnik u jednoj ćeliji mogao da izvrši definisanje recimo promenljive ili funkcije a da je koristi u nekoj drugoj ćeliji. Takav pristup idelano odgovara jezicima koji se interpretiraju što C++ nije. Posle nekog vremena se shvatilo da je notebook pristup primenljiv i na druge interaktivne jezike pa je projekat preimenovan u Jupyter Notebook za koga se razvijaju različita jezgra (oficijalno samo IPython). Ali kako napraviti C++ Jezgro?

Trivijalni pristup bi bio da Jezgro za C++ čuva sve definicije i da ih aranžira u jedan veliki fajl koji bi svaki put morao da bude kompajliran pa izvršen. Ovakav pristup ima mane:

- Kompilacija nepotrebno velikih fajlova je skupa.
- Česta je potreba da korisnik u prvim ćelijama izvrši neku skupu operacije, recimo učita i obradi neku veliku datoteku. Ako bi se sve čuvalo u jednom fajlu koji bi se konstantno ponovo ceo izvršavao onda bi se svaki put ta velika datoteka morala ponovo obrađivati.
- Ne pretstavlja bas interaktivan pristup radu.

Jedinu dužnost koju Jezgro ima jeste komunikacija sa Notebook serverom preko (engl. *ØMQ (a.k.a ZeroMQ)*). Dakle Jezgro može da bude implementiran u bilo kom jeziku i da bude sačinjen iz jednog ili više procesa koji opet mogu biti implementirani u jednom ili više programskih jezika.

Pošto je ovaj projekat implementiran u jeziku python i već postoji klasa (engl. *ipyKernel.kernelbase.Kernel*) koja se može naslediti zarad pravljenja jednostavnog omotača koji implementira *ØMQ*komunikaciju odlučili smo se da prototip implementiramo na taj način. [5]

U ostatku teksta fokusiraćemo se na primenu dinamičkog učitavanja (engl. *dynamic loading*) za simuliranje interaktivnog rada sa C++ jezikom ali prvo treba detaljnije opisati protokol za poruke (engl. *Message protocol*) koji takođe specifikuje zaduženja jednog Jezgra.

3 Protokol za poruke

Bitno je istaći da jedno jezgro može biti konektovano na više klijenata (engl. *font end's*) [5]

Jezgro treba da implementira 4 soketa (engl. *socket*) (prva 3 su bitna): [**?**]

1. **Shell** - (engl. *single Router*) soket, koji podržava konekcije ka nekoliko klijenata. Namenjen je za zahteve izvršavanja koda, ispitivanje objekata itd.
2. **IOPub** - takozvani (engl. *broadcast channel*) koji služi za sve sporedne efekte tipa: stdout, stderr.
3. **stdin** - Ovaj ruter soket je povezan na sve klijente i služi da jezgro zatraži ulaz od korisnika klijenta.
4. **Control** - Isto kao i **Shell** ali služi za abort, shutdown i druge bitne zahteve koji ne treba da čekaju u redu da se pošalju kroz **Shell**.

3.1 Struktura i tipovi poruka

Trenutno poruke se šalju u (engl. *JSON*) formatu a u pythonu se pretstvaljaju Rečnikom rečnika prikazanim u 3 [5]

[5]

```
{
  'header' :{
    'msg' : uuid,
    'username' : str,
    'session' : uuid,
    'msg_type' : str,
    'version' : 5.0
  }

  'parent_header' : dict,
  'metadata' : dict,
  'content' : dict
}
```

Slika 3: Struktura poruke

Nećemo ulaziti u detalje implementacije komunikacije preko *ØMQ*jer korišćenjem (engl. *ipyKernel.kernelbase.Kernel*) klase dobijamo već gotovu osnovu jezgra. Pomenutoj klasi je dovoljno premostiti (engl. *override*) pretefinisane funkcije koje kao povratnu vrednost prosleđuju rečnik koji odgovara povratnoj poruci. [**?**]

Da bi razumeli ponašanje, ulaz i izlaz funkcije koje treba implementirati moramo da znamo koje poruke pristižu i kako odgovoriti na njih. Mi ćemo razmotiti samo par bitnih poruka a željne čitaoca upućujemo na detaljnu dokumentaciju svih poruka:
www.jupyter-client.readthedocs.io/en/latest/messaging.html#messages-on-the-shell-router-dealer-sockets

3.2 Tipovi poruke

Poruka (engl. *execute_result*) 4 je obrađena python funkcijom (engl. *do_execute*).
Ovo je najbitnija funkcija za jezgro jer kao ulaz prima kod koji treba izvršiti a kao izlaz vraća rezultat.

```
execute_request = {
  'code': str,      #kod koji treba izvršiti
  'silent': bool,   #da li se uvećava brojač i ispisuje rezultat
  'store_history': bool, # ne ako je silent = True
  'user_expressions': dict,
  'allow_stdin': True,
  'stop_on_error': False,
}
```

Slika 4: Poruka (engl. *execute_request*)

status rezultata može biti: 'ok', 'error' ili 'abort'. Odgovor sadrži status, broj izvršavanja englexecution_count a zavisno od tipa statusa dodaju se dodatna polja koja možemo videti na prikazu 5

```
execute_reply = {
  'status': = 'abort'
  'execution_count' : int
  # nema dalje
}

execute_reply = {
  'status': = 'error'
  'execution_count' : int

  'payload' : list(dict), # deprecated
  'user_expressions' : dict,
}

execute_reply = {
  'status': = 'error'
  'execution_count' : int

  'ename' : str    # ime greške
  'evalue': str    # vrednsot greške
  'traceback' list  #  trag izvršavanja
}
```

Slika 5: Poruka (engl. *execute_reply*)

Nabrajamo još neke bitne poruke

1. Poruke na **Shell** soketu

- inspect_request / inspect_reply
  Služi za introspekciju objekata

```
inspect_request = {
  'code': str,
  'cursor_pos': int,
  'detail_level': 0 or 1,
}
```

```
inspect_reply = {
  'status': 'ok',
  'found': bool,
  'data': dict,
  'metadata': dict,
}
```

- complete_request / complete_reply
  Dovršavanja koda. Aktivira se sa tasterom 'tab'

```
complete_request = {
  'code': str,
  'cursor_pos': int,
}
```

```
complete_reply = {
  'matches': list,
  'cursor_start': int,
  'cursor_end': int,
  'metadata': dict,
  'status': 'ok'
}
```

- is_complete_request / is_complete_reply
  Kada je klijent jezgra običan (engl. *shell*) enter pokreće izvršavanje naredbe što možda nije ono što želimo. Šta ako korisnik želi da nastavi da kuca u narednom redu. O ponašanju u tom slučaju jezgro odlučuje.

```
is_complete_request = {
  'code': str,
}
```

```
is_complete_reply = {
  'status': str,
  'indent': str,
}
```

2. Poruke na **stdin** soketu

- input_request / input_reply
  Kada jezgro traži ulaz od korisnika klijenta. (scanf recimo)

```
input_request = {
  'prompt': str,
  'password': bool
}
```

```
input_reply = {
  'value': str,
}
```

4 Rad Jezgra

Da bi opisli rad i implementaciju jezgra uzećemo jednostavan primer. Pretpostavimo da je korisnik kreirao tri ćelije. Ćelije su numerisane i izvršavaju se zadatim redosledom. U realnosti jezgro ne zna koja ćelija je koja. On samo dobija kod koji treba da izvrši kao gore pomenuti execute_request a numeracija služi nama da olakša primer.

1. ```
   #include <iostream>
   using namespace std;
   int a = 2;
   string b = "Hello";
   %r cout << a << " "; //%r je magic, opisacemo kasnije
   ```
   ```

```
%r cout << b << endl;
void f(int i, string & s){
  while(i--)
    cout << i << ": "<<  << s << " ";
}
```

2. ```
   void g(void){
     f(a, b);
   }
   ```

3. ```
   %r g(a, b);
   %r a = 5;
   %r g(a, "World");
   ```

Implementacija izvršavanja svake od tri ćelije se sastoji od 3 dela:

1. kompajliranje - Ćelija se prevodi u deljeni obejkat (engl. *shared object, .so*) koji je (engl. *position independent*)
2. dinamičko učitavanje (engl. *dynamic loading*) - jezgro dinamički učitava .so pri čemu se linker razrešava sve extern simbole. Biće reči o ovome kasnije.
3. izvršavanje - ćelija se izvršava. Naša implementacija radi tako što svaki deljeni objekat potencijalno ime funkciju 'run' koja ako postoji biva pozvana nakon učitavanja.

Da bi se kod uspešno izvršio svaka od ćelija se obrađuje na sledeći način:

1. Uklanjamo komentare iz koda ("nije neophodno ali čini (engl. *ad hoc*) parsiranje lakšim")
2. Razrešuju se takozvane magične (engl. *magic*) naredbe. To su naredbe koje počinju sa '%' ili '%%'. O tome više reči kasnije
3. Parsira se prosleđeni izvorni kod i izvlače informacije:
   - globalni simboli koji se definišu u kodu. (promenljive i funkcije, za sada)
   - deklaracije tipova
   - definicije makroa
   - using direktive
   - include naredbe

   Ovo informacije se čuvaju jer će biti potrebne za narednu ćeliju koja se bude izvršavala, verovatno će referisati na nešto što je ova ćelija deklarisala.
4. Sav kod koji ne čini deklaracije i definicije već izraze koje treba evaluirati moramo nekako da razlikujemo od ostatka koda. U našoj implementaciji odabrali smo jednoliniski magiju '%r' da bude prefiks za ovakav izraze. (izraz mora da bude jednoliniski). Ako '%r' postoji onda će na kraju koda biti dodata funkcija 'void __run__(void) ... ' koja će sadržati sve pomenute izraze.
5. Da bi kod uspešno prošao kompilaciju moraju se dodati deklaracije svih refereisanih simbola, include i ostale direktive koje su bile korišćen pri izvršavanju pređašnjih ćelija. Bilo bi idealno dodati samo ono što treba ali to je komplikovano izvesti zato dodajemo sve. Izuzetak su simboli koji imaju novu deklaraciju u smislu da im se menja tip.

Treba primetiti da se svaki prosleđen kod razvrstava na delove sa definicijama i delove sa izrazima koje treba izvršiti. Kako kompilacija i učitavanje definicija simbola ide prvo, kod koji naizmenično ima defincije i izraze nije moguće korektno prevesti na ovaj način. Međutim često je programerska praksa da se prvo navedu sve definicije. Ovo bi se naravno moglo popraviti. Recimo da se svaki izraz ćelije kompajlira pa izvršava, ali to pravi nepotrebnu kompleksnost i nećemo razmatrati takvo rešenje.

Naš primer sa tri ćelije bi bio obrađen ovako:

1. Prva

```
#include <iostream>
using namespace std;
int a = 2;
string b  = "Hello";
void f(int i, const string & s){
  while(i--)
    cout << i << ": " << s << " ";
}
void __run__(void) {
cout << a;
cout << b << endl;
}
-------------
izlaz:
2Hello
```

2. Druga ćelija sadrži samo jednu funkciju ali referiše globalne simbole

```
#include <iostream>
using namespace std;
extern string b  ;
extern int a ;
void f(int i, const string & s);

void g(void){
  f(a, b);
}
  ----------
```

3. Treća ćelija sadrži samo izraz koji treba evaluirati

```
#include <iostream>
using namespace std;

extern string b  ;
extern int a ;
void f(int i, const string & s);
void g(void);

void __run__(void) {
  g();
  a = 5;
  f(a, "World");
```

```
}
  ----------
izlaz:
1: Hello 0: Hello 4: World 3: World 2: World 1: World 0: World
```

Svako izvršavanje koda, može potencijalno da izazove bacanje nekog izuzetka ili signala tipa segmentation fault. Jezgro ne bi smelo da bude ugašeno u slučaju pojave ovakvog tipa greške. Izvršavanje koda i učitavanje onda treba ili raditi u nekom drugom procesu ili bi se više pažnje trebalo posvetiti baratanju izuzecima i signalima.

Još jedan razlog zašto bi izvršavanje trebalo da bude zaseban proces je kad se traži ulaz od korisnika. Proces koji se izvršava može da zalagvi dok jezgro traži ulaz od korisnika.

Naša implementacija nažalost sve obavlja u jednom procesu te stoga i nema mogućnost da korektno obradi potražnju ulaza od korisnika.

4.1 Magije

Ipython je uveo pojam magije (engl. *magic*) kao komande specijalno značenja za proširenje mogućnosti python jezika. IPython jezgro razlikuje: [6]

1. liniske (%komanda) recimo %ls printa sadržaj direktorijum, dok %time 'python-komanda' računa srednje vreme izračunavanje 'python-komande'
2. ćeliske (%%komanda) magija se odnosi na celu ćeliju. Recimo moguće je izvršiti neki jezik koji nije python %%latex ... označava da će ćelija biti obrađena kroz latex

Mi definisemo linisku magiju '%r' koja označava linije koda koje treba izvršiti po ucitavanju. Liniske magije su implementirane kao inekcije c++ koda a ćeliske magije imaju proizvoljnu implementaciju.

4.2 Dinamičko učitavanje

Dinamičko učitavanje (Dynamic loading) je mehanizam da se procesu koji se izvršava učitaju dodatne funkcije, klase itd iz neke biblioteke tj. deljene datoteke (engl. *shared object, .so*) [2]. Najčešća uloga kod kompleksnijih aplikacija jeste proširivanje funkcionalnosti preko takozvanih proširenja (engl. *plugin*). Svaki plugin se kompajlira u zasebni deljeni obejkat koji po potrebi biva učitan u glavnu aplikaciju.

Postoji C biblioteka dlfcn koja definiše funkcije za dinamičko učitavanje (dlopen, dlclose, ...) Takođe Python modul ctypes pored drugih stvari pruža i interfejs ka ovoj biblioteci i znatno pojednostavljuje proces. [1]

```
in.so
==============
extern "C" {
  int a = 25;
  string b = "Hello World";
  vector<int> lista= {1,2,3,4};
  void print(){
    cout << ", "  << b
    << ", " << lista << endl;
  }
}
```

```
in1.so
==============
extern "C" {
  extern int a;
  void print();
  void f(){
    a = 100;
    print();
  }
}
```

Učitavanje u pythonu

```
from ctypes import *
prog = CDLL('./in.so', mode=RTLD_GLOBAL|RTLD_DEEPBIND|RTLD_NOW)
prog.print()
prog1 = CDLL('./in1.so', mode=RTLD_GLOBAL|RTLD_DEEPBIND|RTLD_NOW)
prog1.f()
```

Bitno je uočiti da f() referiše simbole iz prvog in.so deljenog objekta. ctypes niti dlopen ne pružaju mogućnosti samoispitivanja deljenog objekta. Mi moramo da znamo kakve simobole deljeni objekat sadrži. Zato smo gore odabrali da uvek imamo jednu funkciju istog imena __run__.

- RTLD_GLOBAL - govori da će svi učitani simboli biti globalno vidljivi za razrešavanje i [1] pri sledećem učitavanju. To nam je neophodno.
- RTLD_DEEPBIND - govori da će simboli prvo biti traženi u deljenoj datoteci koja se učitava [1]
- RTLD_NOW - govori da će svi simboli biti rešeni pri učitvanju (RTLD_LAZY suprotan flag) [1]

poslednje 3 pomenute opcije nisu definisane u python modulu ctypes. Moraju se dodefinisati. RTLD_DEEPBIND nije specifikovan u POSIX.1-2001

Zanimljivo pitanje koje se nameće jeste. A šta ako u primeru sa 3 ćelije izvršimo još jednu sa kodom

```
long a = 10;
%r cout << a;
```

Dobili bi očekivan izlaz "10".

Međutim ako bi opet u petoj ćeliji pokrenuli "%r cout ¡¡ a;đobili bi ponovo "5". To je zato što je u četvrtoj ćeliji DEEPBIND garantovao da će biti nađen verzija sa long dok u petoj ćeliji pretraga za definicijom 'a' ide linearno i prvo nailazi na deklaraciju sa int. Sve što bi trebalo uraditi jeste pretragu izvršavati od poslednje učitane datoteke do prve ali trenutno ne znamo kako to da izvedemo.

4.3 Parsiranje

Parsiranje C++ izvornog koda je najteži korak. Trenutna implementacija koristi ctags i regularne izrze za od hoc parsiranje. Ovo svakako nije dobra praksa i ubuduće zahteva ozbiljne popravke.

Jedno rešenje je korišćenje biblioteka clang kompajlera. Clang za ovu svrhu nudi dve biblioteke. Lakša je C biblioteka libclang i za nju postoji python binding. [4]

Ispod dajemo kratak primer koji prikazuje parsiranje jednog cpp fajla. Ne ispisujemo sve čvorove apstraktnog stabla parsiranja jer nisu potrebni. Nažalost još nismo sigurni kako da dobijem sve informacije koje su nam potrebne.

```
test.cpp
===========
#include <stdio.h>
int a = 42;
float b= 3;
int * p, & nop(a), x;

int f(){
  int c = 4 + b;
  return a + c;
}
struct Vec{
  int x, y;
};
float g(int a, int b){
  return a*b;
}
static char c = 'x';
int main(){
  return 0;
}
```

```
parsing test.cpp
============
test.cpp (TRANSLATION_UNIT) :
  a (VAR_DECL) :  int a = 42 ;
     (INTEGER_LITERAL) :
  b (VAR_DECL) :  float b = 3 ;
     (UNEXPOSED_EXPR) :
       (INTEGER_LITERAL) :
  p (VAR_DECL) :  int * p ,
  nop (VAR_DECL) :  int * p , & nop ( a )
    a (DECL_REF_EXPR) :
  x (VAR_DECL) :  int * p , & nop ( a ) , x ;
  f() (FUNCTION_DECL) :  int f ( ) { int c = 4 + b ; r
  Vec (STRUCT_DECL) :  struct Vec { int x , y ; } ;
    x (FIELD_DECL) :  int x ,
    y (FIELD_DECL) :  int x , y ;
  g(int, int) (FUNCTION_DECL) :  float g ( int a , int
    a (PARM_DECL) :  int a ,
    b (PARM_DECL) :  int b )
  c (VAR_DECL) :  static char c = 'x' ;
     (CHARACTER_LITERAL) :
  main() (FUNCTION_DECL) :  int main ( ) { return 0 ;
```

python binding za libclang ne pokriva sve mogućnosti biblioteke ali se zato to može lako dodati. Veći probelm je što sama biblioteka libclang iako stabilna ne pruža finu kontrolu nad generisanim apstraktnim stablom.

5 Zaključak

U ovom radu pretstavili smo softver Jupyter Notebook i istražili smo mogućnosti razvoja Jezgra za C++ jezik koji bi izvršavao c++ kod. Pokazali smo da je tehnikom dinamičkog učitavanja moguće donekle simulirati interpretaciju ali i dalje postoje male razlike koje bi trebalo rešiti. Implementacija pravog Jezgra bi se mnogo više oslanjala na libclang biblioteku. U našim razmatranjima libclang je korisna za parsiranje ali postoje i mnoge druge dužnosti Jezgra kao što je samoispitivanje objekata, dovršavanje koda itd.

Literatura

[1] dlopen man page. on-line at: http://linux.die.net/man/3/dlopen.

[2] John R. Levine. *Linkers and Loaders*. Morgan Kaufman, 1999.

[3] Jupyter project team. Jupyter project, 2016. on-line at: http://jupyter.org/.

[4] Clang team. Clang, 2016. on-line at: http://clang.llvm.org/.

[5] Ipython team. Ipython Developer documentation, 2014. on-line at: https://ipython.org/ipython-doc/3/development/.

[6] Ipython team. Ipython magic documentation, 2014. on-line at: https://ipython.org/ipython-doc/3/interactive/magics.html.